

MCS笔记day15

日期： 2026-10-07

day 15 笔记

主题：特征值与特征向量

震动分析(物理引擎)：固有频率，刚度矩阵和质量矩阵的特征值
特征值分析，确保结构安全

量子力学(物理)：物理量(能量)由算符(矩阵)表示
物理量→线性算符→选取基底→矩阵
测量结果是特征值(本征值)

薛定谔方程
本质

$$\hat{H}\Psi = i\hbar \frac{\partial}{\partial t} \Psi$$

其中， $\hat{H}$ 是表征波函数总能量的哈密顿算符， Ψ 是物理系统的波函数， i 是虚数单位， $\hbar$ 是约化普朗克常数， $\partial/\partial t$ 是对于时间 t 的偏微分。

$$\hat{H}\psi = E\psi$$

其中， ψ 是不含时波函数， E 是能量。

这方程的诠释为，假若将哈密顿算符作用于波函数 ψ 时，得到的结果态 ψ 的能量。在这里， ψ 标记设定的波函数和其对应的量子态。这方程本征薛定谔方程”， E 是“能量本征值”，或“本征能量”。

E (能量特征值) 可以看作特征值(不同学界的叫法)
 ψ

稳定性分析(控制论)：动态系统是否稳定，核心取决于系统的特征值（或极点）的位置
如果所有特征值的实部都 <0 ，系统就是稳定的(数值上：会衰减至 0)
如果所有特征值的实部都 >0 ，系统就是发散的(会爆炸)

特征值 λ	稳定性
所有 $\text{Re}(\lambda) < 0$	渐近稳定

特征值 λ	稳定性
存在 $\text{Re}(\lambda) > 0$	不稳定
有 $\text{Re}(\lambda) = 0$	需要进一步判断

要求：

1. 会求解特征值和特征向量
2. 验证一些理论(比如：矩阵的迹等于特征值之和，行列式等于特征值之积)
3. 对称矩阵，验证特征向量互相正交
4. 学会用 python 去计算矩阵、特征值(本征值)、
5. 用 PCA 对二维数据降维

提问：

特征值是否可以为 0？

可以。特征值为 **0** 意味着矩阵存在非零向量被映射为零向量，因此矩阵不可逆。

对于特征值问题： $Av = \lambda v$

当 $\lambda = 0$ 时，有 $Av = 0$

这意味着存在一个非零特征向量 $\mathbf{v}$ ，经过矩阵 A 的变换后被映射为零向量。几何上可以理解为：矩阵在该特征向量所对应的方向上，将数据完全压缩，使该方向的信息丢失。

从行列式角度来看，特征值满足特征方程： $\det(A - \lambda I) = 0$

因此，特征值就是特征多项式的根。对于 $n \times n$ 矩阵，其特征值满足： $\det(A) = \prod_{i=1}^n \lambda_i$

所以，只要存在一个特征值为 0，就有： $\det(A) = 0$

进而说明矩阵 A 不可逆。

从几何角度来看，例如一个二维线性变换可以将整个二维平面压缩成一条直线。此时，被压缩掉的那个方向对应的特征值可能为 0；如果两个独立方向都被压缩，则整个平面甚至可能被映射到一个点。

因此，零特征值并不是异常情况，它表示线性变换在某个方向上完全丢失了信息。

在 PCA 中，这一点尤其重要：如果协方差矩阵存在零特征值，说明数据在对应方向上的方差为 0，即数据在该方向上没有实际变化。因此，该方向不包含额外的方差信息，可以不作为有效的主成分保留。

核心理解：零特征值 $\rightarrow$ 某个方向被完全压缩 $\rightarrow$ 该方向信息丢失 $\rightarrow$ 矩阵不可逆；在 PCA 中则意味着该方向方差为 0。

可以，这段主要需要把“单位化是数学定义要求”和“单位化是数值计算中的规范化选择”区分清楚。尤其是最后一句，“为了结果唯一”不够准确，因为单位向量仍然存在正负号的不唯一性。

特征向量一定是单位向量吗？

不一定。特征向量不要求是单位向量，只要向量非零且方向满足特征值方程即可。

根据特征向量的定义： $Av = \lambda v$, $v \neq 0$

如果 v 是特征值 λ 对应的特征向量，那么对于任意非零标量 c ，都有：

$$A(cv) = cAv = c\lambda v = \lambda(cv)$$

因此， $[cv]$ 同样是对应于特征值 λ 的特征向量。

这说明，特征向量的长度并不重要，真正重要的是它所表示的方向。对一个特征向量进行非零倍缩放，只会改变其长度，甚至改变其方向的正负，但不会改变它所属的特征方向。

因此，在数学计算中，特征向量可以根据需要选择不同的形式。例如，手算时通常会选择整数形式，以简化计算。

而在数值计算中，通常会进一步对特征向量进行归一化： $\|v\| = 1$

例如，NumPy 的 `np.linalg.eig()` 通常返回经过单位化处理的特征向量。这样做可以统一输出尺度，便于后续计算、比较以及构造正交归一基。

需要注意的是，单位化并不能让特征向量完全唯一。如果 v 是单位特征向量，那么 $-v$ 也是单位特征向量，因为： $\|-v\| = 1$

并且： $A(-v) = \lambda(-v)$

所以通常只能确定特征向量的方向轴，而不能唯一确定正负方向。

特征向量不一定是单位向量；特征向量的本质是确定一个特征方向，而不是确定一个固定长度的向量。单位化只是为了规范化表示和便于数值计算。

可以把这一点 和 PCA 连起来：

特征向量：确定方向 特征值：确定该方向上的缩放/方差大小

这也是为什么 PCA 最后可以直接把单位特征向量拼成投影矩阵。因为协方差矩阵是实对称矩阵，它的特征向量可以选取为两两正交且单位化的形式，从而直接构成一组正交归一基。

所有的矩阵都有特征值吗？

不是所有矩阵都有实特征值。

需要根据矩阵所在的数域以及矩阵的类型进行区分：

- 实方阵：不一定存在实特征值；
- 复方阵：一定存在至少一个复特征值，并且在复数域中可以找到全部特征值；
- 实对称矩阵：一定存在实特征值，而且全部特征值都是实数。

1. 特征值来自特征方程

特征值由特征方程确定： $\det(A - \lambda I) = 0$

对于一个 $n \times n$ 矩阵，该方程是关于 λ 的 n 次多项式。

如果限定在实数范围内：

- 奇数次实系数多项式至少存在一个实根；
 - 偶数次实系数多项式不一定存在实根。
- 因此，实矩阵并不一定具有实特征值。

2. 经典例子：二维 90° 旋转矩阵

考虑二维平面上的 90° 旋转矩阵：

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

其特征方程为：

$$\det(A - \lambda I) = \begin{vmatrix} -\lambda & -1 \\ 1 & -\lambda \end{vmatrix} = 0$$

因此： $\lambda^2 + 1 = 0$

得到： $\lambda = \pm i$

所以，这个矩阵虽然是实矩阵，但它没有实特征值，而是在复数域中具有两个特征值：

$$\lambda_1 = i, \quad \lambda_2 = -i$$

几何上，这说明二维 90° 旋转不存在一个实方向，使得向量经过变换后仍然保持在原来的方向上并仅发生缩放。

换句话说，不存在非零实向量 v 满足： $Av = \lambda v, \quad \lambda \in \mathbb{R}$

因为旋转会改变向量的方向，而不是仅仅沿原方向进行拉伸或压缩。

3. 为什么实对称矩阵一定有实特征值？

对于实对称矩阵： $A = A^T, \quad A \in \mathbb{R}^{n \times n}$

根据实对称矩阵的谱定理：

实对称矩阵的所有特征值都是实数，并且存在一组两两正交的单位特征向量。

因此： $A = Q\Lambda Q^T$

其中：

- Q 是由单位特征向量组成的正交矩阵；
- Λ 是由实特征值组成的对角矩阵；
- 满足 $Q^T Q = I$ 。

这也是 PCA 可以使用协方差矩阵进行特征分解的数学基础，因为协方差矩阵是实对称矩阵。

实矩阵 $\nRightarrow$ 一定有实特征值

但：实对称矩阵 $\Rightarrow$ 一定有实特征值

而在复数域中，对于任意复方阵： $A \in \mathbb{C}^{n \times n} \Rightarrow$ 至少存在一个复特征值

因此，判断一个矩阵“有没有特征值”时，首先要明确：

矩阵是否为方阵，以及我们是在实数域还是复数域中讨论。

PCA 为什么用协方差矩阵

(对于实对称矩阵，不同特征值对应的特征向量一定正交；同一特征值对应的特征向量也可以通过正交化，选成一组相互正交的特征向量。)(协方差矩阵是对称的，特征向量是正交的，可以得到一组正交基，协方差矩阵的特征值反映了数据在其对应方向上的方差大小。)

PCA 之所以基于协方差矩阵进行分析，是因为协方差矩阵天然契合 **PCA** 的核心目标：寻找一组相互正交的方向，并按照数据在这些方向上的方差大小进行排序。

假设数据已经完成中心化，即各特征的均值为 0。设中心化后的数据矩阵为 XX ，则协方差矩

阵可表示为

$$C = \frac{1}{N-1} X^T X$$

(有些教材使用 $\frac{1}{N}$ ，具体取决于采用总体协方差还是样本协方差的定义。)

由于 C 是实对称矩阵，根据实对称矩阵的谱定理，它一定存在一组两两正交的单位特征向量。因此，这些特征向量可以直接构成一组正交归一基，不需要额外使用 Gram-Schmidt (GS) 正交化进行处理。

进一步地，将中心化后的数据投影到某个单位特征向量 v 上： $z = Xv$

其方差为 $\text{Var}(z) = v^T C v$

由于 v 是 C 对应于特征值 λ 的单位特征向量，即 $Cv = \lambda v$

因此： $\text{Var}(z) = v^T C v = v^T (\lambda v) = \lambda v^T v = \lambda$

所以，协方差矩阵的特征值恰好表示数据在对应特征向量方向上的方差。特征值越大，说明数据在该方向上的离散程度越大，也意味着该方向能够保留更多的数据变化信息。

因此，PCA 的基本流程为：

中心化 $\rightarrow$ 计算协方差矩阵 $\rightarrow$ 特征分解 $\rightarrow$ 按特征值降序排列 $\rightarrow$ 选取前 K 个特征向量 $\rightarrow$ 构造投影

取前 K 个最大特征值对应的特征向量： $W = [v_1, v_2, \dots, v_K]$

将中心化后的数据投影到由这些特征向量构成的 K 维子空间： $Z = XW$

从而将原来的高维数据压缩到保留最大方差的低维子空间中。

因此，协方差矩阵并不是 PCA 中凭空引入的矩阵，而是将“最大化投影后的方差”这一几何目标转化为“寻找协方差矩阵最大特征值对应的特征向量”这一可计算的代数问题，从而建立了几何直觉与线性代数求解之间的联系。

PCA 利用协方差矩阵的特征分解，将“寻找最大方差的正交方向”转化为“寻找最大特征值对应的特征向量”，再利用这些特征向量构成投影矩阵，实现高维数据的降维。

特征值分解和 SVD 的区别

1. 适用对象不同

特征值分解 (**Eigendecomposition**) 主要针对方阵，而 **SVD** 可以处理任意形状的矩阵。

对于一个方阵： $A \in \mathbb{R}^{n \times n}$

可以研究其特征值问题： $Av = \lambda v$

如果矩阵具有足够多的线性无关特征向量，则可以进行特征值分解： $A = V \Lambda V^{-1}$

对于实对称矩阵，还可以进一步写成： $A = Q \Lambda Q^T$ ，其中 Q 是正交矩阵。

而现实中的数据矩阵往往不是方阵。例如： $A \in \mathbb{R}^{m \times n}$

其中 m 可以表示样本数量， n 可以表示特征数量，因此 m 和 n 通常并不相等。

对于这种矩阵，通常不能直接讨论普通意义上的特征值分解，但可以使用 **SVD**。

2. SVD 可以处理任意形状的矩阵

对于任意矩阵： $A \in \mathbb{R}^{m \times n}$

都可以进行奇异值分解： $A = U \Sigma V^T$

其中：

- $U \in \mathbb{R}^{m \times m}$ ：左奇异向量组成的正交矩阵；

- $\Sigma \in \mathbb{R}^{m \times n}$: 奇异值矩阵;
- $V \in \mathbb{R}^{n \times n}$: 右奇异向量组成的正交矩阵。

满足: $U^T U = I$

以及: $V^T V = I$

因此, U 和 V 分别提供了输入空间和输出空间中的正交归一基。

3. SVD 中的奇异值是什么?

SVD 中的奇异值 σ_i 与 $A^T A$ 的特征值之间存在直接关系。

设: $A^T A v_i = \lambda_i v_i$

那么对应的奇异值满足: $\sigma_i = \sqrt{\lambda_i}$

也就是说: $\sigma_i^2 = \lambda_i(A^T A)$

因此, 奇异值本质上是 $A^T A$ 的特征值的平方根。

同样, 也可以通过 AA^T 得到相同的非零奇异值:

$$AA^T u_i = \sigma_i^2 u_i$$

所以: $A^T A$ 和 AA^T 的非零特征值相同, 并且等于 σ_i^2

4. 为什么 SVD 可以看作特征值分解的推广?

对于矩阵 A : $A = U \Sigma V^T$

可以构造: $A^T A = (U \Sigma V^T)^T (U \Sigma V^T)$

由于: $(U \Sigma V^T)^T = V \Sigma^T U^T$

因此: $A^T A = V \Sigma^T U^T U \Sigma V^T$

由于: $U^T U = I$

所以: $A^T A = V \Sigma^T \Sigma V^T$

这实际上就是 $A^T A$ 的特征值分解。

因此:

$$V = A^T A \text{ 的特征向量}$$

而:

$$\sigma_i^2 = A^T A \text{ 的特征值}$$

同理: $AA^T = U \Sigma \Sigma^T U^T$

因此 U 的列向量是 AA^T 的特征向量。

5. 特征值分解和 SVD 的核心区别

可以从几个方面进行对比:

对比	特征值分解	SVD
适用矩阵	方阵	任意矩阵
是否要求方阵	是	否
是否一定存在	不一定能完整对角化	一定存在
分解形式	$A = V \Lambda V^{-1}$	$A = U \Sigma V^T$
主要对象	特征值、特征向量	奇异值、左右奇异向量

对比	特征值分解	SVD
奇异值	—	$\sqrt{A^T A}$ 的特征值
正交性	一般不保证	U, V 可以取为正交矩阵
稳定性	一般情况下不如 SVD	数值计算中通常更稳定

需要特别注意：

特征值分解只适用于方阵”并不意味着所有方阵都一定能够写成 $A = V \Lambda V^{-1}$ 。

一个方阵只有在具有足够多的线性无关特征向量时，才能进行这样的完整特征值分解。

而 SVD 对任意实矩阵或复矩阵都存在。

6. 从几何角度理解 SVD

SVD: $A = U \Sigma V^T$

可以理解为一个线性变换被拆成三个连续步骤： $V^T \rightarrow \Sigma \rightarrow U$

第一步： V^T

首先通过 V^T 对输入空间进行一个正交变换。

因为 V 是正交矩阵，所以： $V^T V = I$

这个变换本质上不会改变长度和角度，可以理解为旋转或反射。

第二步： Σ

然后通过 Σ 对不同的正交方向进行不同程度的缩放：

$$\Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{pmatrix}$$

其中： $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$

每个奇异值表示矩阵在对应方向上的缩放倍数。

第三步： U

最后再通过 U 对结果进行另一个正交变换。

因此，SVD 可以理解为： $\boxed{\text{旋转/反射} \rightarrow \text{沿正交方向缩放} \rightarrow \text{旋转/反射}}$

这就是 SVD 非常重要的几何意义。

7. 为什么 SVD 特别适合矩阵分析？

SVD 的一个重要优势是，它不要求矩阵本身具有特征值分解所要求的结构。

即使： $A \in \mathbb{R}^{m \times n}$

是一个长方形矩阵，仍然可以写成： $A = U \Sigma V^T$

而且奇异值始终满足： $\sigma_i \geq 0$

因此，SVD 可以非常自然地描述一个矩阵对不同方向的缩放程度。

其中：

- σ_i 很大：该方向经过矩阵变换后被明显保留或放大；
- σ_i 很小：该方向经过变换后被明显压缩；

- $\sigma_i = 0$: 该方向被完全压缩, 信息丢失。
这与前面讨论的零特征值有类似的几何意义。

8. SVD 与 PCA 的联系

PCA 中, 我们对协方差矩阵:

$$C = \frac{1}{N-1} X^T X$$

进行特征值分解: $C = V \Lambda V^T$

而如果直接对中心化后的数据矩阵 X 进行 SVD: $X = U \Sigma V^T$

那么: $X^T X = V \Sigma^T \Sigma V^T$

因此:

$$C = \frac{1}{N-1} V \Sigma^T \Sigma V^T$$

所以 PCA 中的主成分方向, 就是 X 的 SVD 中的右奇异向量:

$$\boxed{\text{PCA 主成分方向} = \text{SVD 的右奇异向量}}$$

并且:

$$\boxed{\lambda_i = \frac{\sigma_i^2}{N-1}}$$

因此:

$$\boxed{\sigma_i = \sqrt{(N-1)\lambda_i}}$$

这也解释了为什么 PCA 经常可以直接使用 SVD 来计算, 而不必显式地构造协方差矩阵。

特征值分解关注的是: $\boxed{Av = \lambda v}$

即:

寻找经过矩阵变换后仍然保持在原方向上的向量, 以及对应的缩放倍数。

而 SVD 关注的是: $\boxed{A = U \Sigma V^T}$

即:

寻找输入空间和输出空间中的正交方向, 并描述矩阵在这些方向上的缩放程度。

$$\boxed{\text{特征值分解: 方阵的“自身方向”}}$$

SVD: 任意矩阵的“输入方向 $\rightarrow$ 缩放 $\rightarrow$ 输出方向”